

矩阵的隐喻：解剖大模型概念空间与偏见

线性特征提取在现代 NLP 表征中的应用

第五组

南京大学

March 22, 2026

理论基础：作为概念提取器的特征分析

传统视角： PCA 是一种降维压缩工具。

大模型视角（线性表征假说）： 深度神经网络会在高维隐空间中，使用简单的线性方向来编码高级的抽象语义（如性别、时态）。

我们构建带有“性别”对立关系的词向量差值矩阵 $X \in \mathbb{R}^{n \times d}$ ：

$$X_{diff} = \vec{Word}_{male} - \vec{Word}_{female}$$

求解其协方差矩阵的特征分解（或直接 SVD）：

$$\Sigma \mathbf{v}_i = \lambda_i \mathbf{v}_i \quad \text{其中} \quad \Sigma = \frac{1}{n-1} X^T X$$

物理意义： 最大特征值对应的特征向量 $\mathbf{v}_1$ ，即为空间中的“性别概念方向”。

概念透视：差值矩阵、特征分解与 SVD

为了更直观地理解上述数学操作的核心：


- **词向量差值矩阵 (X)**：收集“男性-女性”等配对词的差异走向。每一行代表一个“差异箭头”，记录了性别区别在不同词对中的表现。
- **协方差矩阵 (Σ) 与特征分解**：目的在于分析这些向量的整体分布。其最大特征值对应的特征向量代表“核心共识方向”（即性别主干线），而特征值大小则反映该极化方向上的统治力。
- **奇异值分解 (SVD)**：与特征分解殊途同归（ V 矩阵等同于协方差的特征向量），可以对原始差异矩阵一步到位提取主干方向。
- **解释方差占比**：衡量主成分的显著性。单方向占比若极高（如 30.40%），说明在该空间内“性别”这一法则占据了大量的语义信息。

提取结果：高维空间中的线性“性别”

特征分析结果：

- 提取特征向量 $\mathbf{v}_{gender}$
- 第一主成解释方差占比：30.40%
- (在 100 维稠密空间中属于极强的单向显著性信号)

几何直觉：如图所示，尽管词汇间包含了阶级、年龄等复杂差异，但在投影平面上，所有性别对立词的连线保持着较好的平行且等距关系。



矩阵投影操作：概念抹除与正交坍塌

操作公式：使用正交投影，消除目标词汇在 $\mathbf{v}_{gender}$ 方向上的分量：

$$\mathbf{x}_{neutral} = \mathbf{x} - (\mathbf{x}^T \mathbf{v}_{gender}) \mathbf{v}_{gender}$$

预期与实际结果：我们预期 King 抹去性别特征后会变成中性的 Ruler。然而真实数据表明：

手术前 (Original King)		手术后 (Neutralized King)	
最近邻词	余弦相似度	最近邻词	余弦相似度
prince	0.768	queen	0.850 (↑)
queen	0.751	prince	0.777
son	0.702	monarch	0.709 (New)

解释：King 和 Queen 原本是被性别维度强行拉开的。当正交投影抹平该维度后，两者坍塌到了同一个概念坐标点——纯粹的“王权”。

谱聚类观测：流形空间中的历史偏见与跨簇迁移

为了更严谨地观察，我们构建了 K-NN 相似度图，并求解拉普拉斯矩阵进行谱聚类。

1. 手术前 (Baseline) :

- 簇 A (统治者): monarch, ruler, leader, **king**
- 簇 B (象征物): crown, throne, palace, scepter, **queen**

发现：在未经干预的原始空间中，*Queen* 已经被边缘化为“附属象征物”。

2. 手术后 (正交投影后):

- 簇 A (统治者): monarch, ruler, leader
- 簇 B (象征物): crown, throne, ..., **neutral_queen, neutral_king (↓)**

现象：消除性别分量后，*King* 发生了跨簇迁移，被归类至“象征物”簇。


概念透视：谱聚类、拉普拉斯矩阵与正交投影

- **图拉普拉斯矩阵 (L)**: 用于刻画相似度网格结构的工具。其特征分解能够揭示图谱的连通性，天然定位出结构中最易发生分离的“断裂带”。
- **谱聚类 (Spectral Clustering)**: 基于上述拉普拉斯矩阵，结合高维词向量的余弦相似度自动聚类划分圈层。
- **正交投影** ($x_{neutral} = x - (x^T v_{gender}) v_{gender}$): 将词汇沿着目标概念主干强行坍塌（消除影子），进而获得纯净的中立语义。

场景诠释（跨圈社交隐喻）:

- **原始状态**: King 加入含有 Ruler 的“统治者俱乐部”；而 Queen 却和王冠等“附属物”混在一起。
- **抹除与重构**: 经过“性别特征切除手术”后，King 无法继续立足于原来的统治者圈，反而加入了 Queen 的“象征物”圈。
- **内核**: 这意味着原始模型中 King 与前者的相似性很可能源自共享的“男性主导特征”，一旦剥离，真实的权力身份仅仅退化成了一个符号。

K-NN 相似度图与谱聚类可视化



深入分析：语义纠缠与投影的连带影响

为什么 Neutral King 没有留在统治者簇，而是变成了“物品”？

- **数据分布的特征耦合：**协方差矩阵提取的 $\mathbf{v}_{gender}$ 不仅仅是生理性别，由于真实语料库的统计分布，该方向也耦合了“**主导权/主动性 (Agency)**”的方差。
- **正交投影的数学作用：** $\mathbf{x} - (\mathbf{x}^T \mathbf{v}_{gender}) \mathbf{v}_{gender}$ 的数学操作，不仅消除了 King 的性别分量，也同时移除了与该方向共线的“主动统治”相关的语义特征。

进一步探讨：用矩阵运算量化语料库偏见

为何原始空间中的 Queen 偏向物品？根据矩阵分解原理 $\vec{w}_i^T \vec{w}_k \approx \log P(k|i)$ ，推导出共现概率比 (Log-Odds Ratio)：

$$\vec{w}_k^T (\vec{w}_{king} - \vec{w}_{queen}) \approx \log \frac{P(k|king)}{P(k|queen)}$$

预训练权重真实测算结果：

探针词汇 (k)	Log-Odds	矩阵逆推的原始语料共现概率比
rule (统治)	+8.2889	偏向 King 3979.52 倍
command (指挥)	+5.4165	偏向 King 225.10 倍
beautiful (美丽)	-5.2150	偏向 Queen 184.01 倍
wear (穿戴)	-3.6510	偏向 Queen 38.51 倍

结论：矩阵运算能量化分析数据中的群体偏见分布。特征分析不仅是降维工具，也是解释模型内部表征的重要方法。

前沿应用：大模型对齐与高维知识检索

上述在静态词向量上的矩阵投影与干预操作，也是当前深度学习中部分研究的底层思想：

1. 大模型表征工程 (Representation Engineering, RepE):

- 现代 LLM 在推理时，我们可以收集其动态隐藏层激活矩阵 (Hidden States)。
- 利用 PCA 提取出代表“诚实 (Truthfulness)”或“安全 (Safety)”的特征向量 $\mathbf{v}_{concept}$ 。
- 推理时直接执行向量干预 $\mathbf{h}_{new} = \mathbf{h} \pm \alpha \mathbf{v}_{concept}$ ，无需微调即可在一定程度上影响模型输出行为或对齐价值观。

2. 检索增强生成 (RAG) 中的拓扑切分:

- 在构建面向垂直领域（如 AI4Math、AI4Sci）的复杂知识库时，海量文档的稠密向量往往会产生严重的语义纠缠。
- 利用谱聚类与图拉普拉斯特征分析，可以在高维流形上对 Document Embeddings 进行严谨的拓扑切分，构建层次化检索树，大幅降低 RAG 的幻觉与检索噪声。

Thanks.